

- При обсуждении процессов и потоков мы говорили о переключении контекстов
- Мы обошли вопрос выбора следующего процесса или потока на исполнение
 - "выбирается поток из очереди готовых к выполнению"
- Принятие такого решения называется планированием
 - планирование это стратегия (policy)
 - переключение контекстов используемый механизм

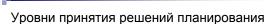


Планирование

- Сегодня:
 - Стратегии планирования
 - Кого выбрать на исполнение и на какое время?
 - Объекты планирования: задачи
- Процессы, потоки, люди, перемещение головок диска, ... • Планировщик передвигает задачи из очереди в очередь
- Алаоритм планирования определяет выбор задачи на исполнение, выбор очереди для ожидания
 - Планировщик запускается когда:
 - Исполняемая задача переходит в состояние ожидания
 - Происходит прерывание
 особенно прерывание таймера
 - Создается или уничтожается новая задача
- Много классов планирования...
 - Пакетный (batch), интерактивный, реального времени, параллельный
 - В основном мы будем обсуждать интерактивные планировщики







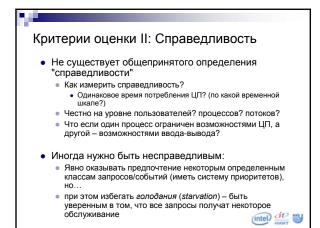
- Долговременное планирование
 - Нужно ли запустить очередную задачу на исполнение или
 - Характерно для систем пакетной обработки
 - По какой причине вы можете решить не запускать задачу?
- Средневременное планирование
 - Нужно ли временно пометить выполняющуюся программу "не запускаемой" (например, при выгрузке ее на диск – swapped out)
- Краткосрочное планирование
 - Какому потоку передать ЦП? На какое время?
 - Какая операция ввода-вывода на диск должна быть выполнена следующей?

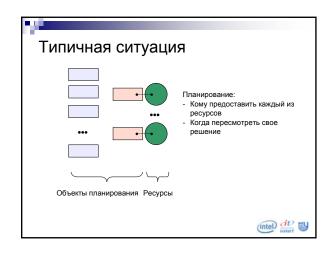


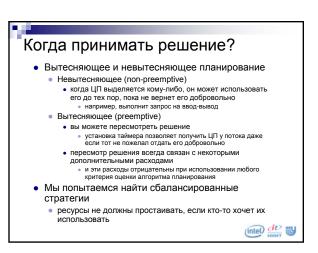
Критерии оценки І: Производительность

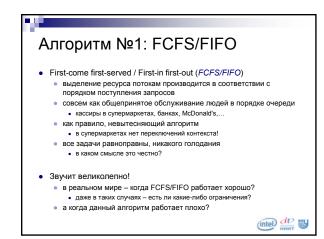
- Существуют различные метрики, оценивающие производительность (иногда – противоречивые)
 - эффективность, CPU utilization (→ MAX)
 - средний процент загруженности ЦП
 - пропускная способность, throughput (→ MAX)
 - среднее число выполненных задач за единицу времени
 - оборотное время, turnaround time (→ MIN)
 - среднее время от момента получения задачи до ее выполнения
 - время ожидания, waiting time (→ MIN)
 - среднее время, проведенное на очереди ожидания
 - время отклика, response time (→ MIN)
 - среднее время, проведенное на очереди готовности
 - потребляемая энергия (Дж/инструкция, → MIN)
 - причина для дополнительных ограничений



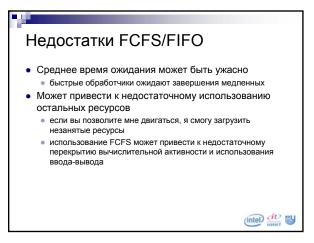










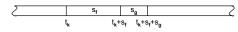




- Shortest job first (SJF)
 - на выполнение выбирается запрос с наименьшими требованиями к обслуживанию
- Оптимальный с точки зрения среднего времени ожидания







- При любом планировании, отличном от SPT/SJF, существуют пары запросов f и g, для которых время обслуживания запроса f (равное s_f), превышает время обслуживания g (равное s_a)
 - T.e. s_f > s_q
- Полный вклад в среднее время ожидания от f и g равен 2t_k+s_f
- Если поменять местами f и g, их суммарный вклад станет равен $2t_k + s_a$, что меньше, так как $s_a < s_f$

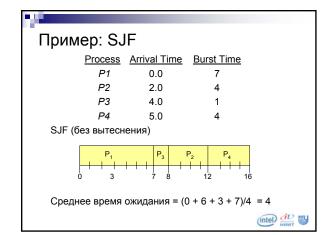


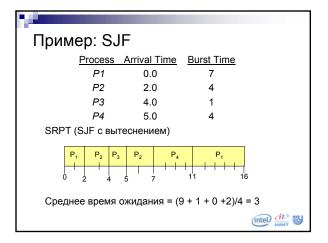


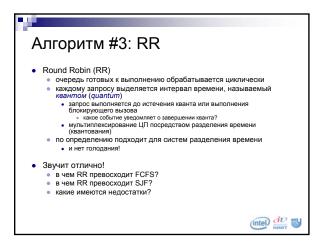


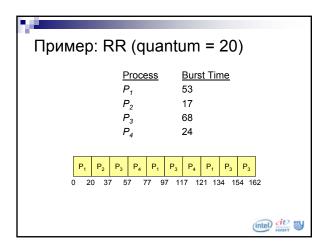
- Невытесняющий алгоритм
- Но существует вытесняющая версия SRPT (Shortest Remaining Processing Time first) учитывающая появление новых запросов (а не предполагающая, что все запросы обрабатываются целиком)
 - Возможно, что только что появившийся запрос выполнится быстрее, чем оставшая часть текущего запроса
- Имеет ли место голодание?
- Можно ли узнать время обработки запроса?
- Можно ли его оценить/предсказать? как?

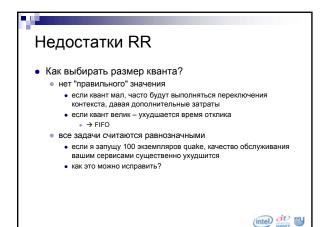












Алгоритм №4: Приоритетное планирование Запросам присваиваются приоритеты

- всегда на исполнение выбирается запрос с наивысшим приоритетом
 - для запросов одного приоритета используется другой алгоритм планирования (например RR) для реализации SJF можно использовать приоритет, равный
- ожидаемому времени потребления ЦП Теоретически моделируется (и обычно практически
- реализуется) в виде множества "очередей приоритетов" запрос, готовый к выполнению, помещается в конец очереди для
 - своего приоритета



Недостатки приоритетного планирования

- Как вы собираетесь назначать приоритеты?
- - если постоянно существуют высокоприоритетные запросы в состоянии "готов к выполнению", низкоуровневые запросы могут никогда не выполниться
- Решение: организовать "устаревание" запросов
 - увеличивать приоритет в зависимости от накопленного времени ожидания
 - уменьшать приоритет в зависимости от количества уже потребленного времени ЦП
 - к настоящему моменту существует масса эвристических алгоритмов изменения приоритетов



Комбинированные алгоритмы

- На практике, каждая реальная система использует некоторый комбинированный подход с элементами FCFS, SJF, RR и приоритетного планирования
- Пример: многоуровневые очереди с обратной связью (multi-level feedback queues, MLFQ)
 - это иерархия очередей
 - очереди упорядочены по приоритетам
 - новый запрос поступает в очередь с наивысшим приоритетом
 - внутри каждой очереди реализован алгоритм RR
 - очереди имеют разный размер кванта
 - запросы перемещаются между очередями в зависимости от своей истории выполнения
 - В каких ситуациях MLFQ становится похож на SJF?



Планирование в UNIX

- Оригинальный алгоритм планирования сильно похож на MLFQ
 - 3-4 класса приоритетов, включающие ~170 уровней приоритетов
 - разделения времени: низшие 60 приоритетов
 - системные: средние 40 приоритетов
 - реального времени: высшие 60 приоритетов
 - приоритетное планирование между очередями, RR внутри
 - процесс с наивысшим приоритетом всегда выполняется первым процессы с одинаковым приоритетом планируются по RR
 - у процессов динамически изменяются приоритеты
 - увеличиваются со временем, если процесс перешел в состояние ожидания до завершения своего кванта
- уменьшаются, если процесс потребил свой квант целиком
- Цель:
 - дать интерактивным задачам преимущество перед задачами. просто потребляющим ЦП
 - интерактивные процессы, как правило, потребляют время ЦП малыми порциями





Выводы

- Существует несколько уровней планирования
- Выбор алгоритма планирования очень сильно отражается на производительности
 - и разница увеличивается при изменяющихся требованиях сервисов, обрабатывающих запросы
- Имеется набор критериев оценки алгоритмов планирования, в некоторых случаях – противоречащих друг другу
- Существует множество "чистых" алгоритмов, на практике обладающих рядом недостатков FCFS, SJF, RR, приоритетный
- В реальных системах используются комбинированные алгоритмы





